

4. Modelos lineales generalizados

Introducción a los modelos de regresión generalizados

- Los modelos de regresión en general, son las herramientas estadísticas más usadas en la práctica. Estudian la relación entre dos o más variables observables “y” y “x”. En general estamos interesados en la distribución condicional de y dado x, parametrizada por $f(y|\beta, x)$, en donde se tienen acceso a n observaciones (x_i, y_i) condicionalmente independientes.
- Existen muchas formas de especificar la relación entre “y” y “x” (modelos lineales generalizados, regresión lineal y no lineal, paramétricos y no paramétricos).
- La variable de interés “y” se conoce como *variable respuesta* y puede ser de naturaleza continua, discreta o categórica, mientras que las variables $x' = (x_1, x_2, \dots, x_{p-1})$ son llamadas *variables explicativas o predictoras* y también pueden ser discretas, continuas o categóricas.
- **MODELO LINEAL NORMAL:** Sean $Y_i, x_i' = (1, x_{i1}, x_{i2}, \dots, x_{ip-1})$, $i=1, 2, \dots, n$ un conjunto de variables aleatorias tal que

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip-1} + \varepsilon_i$$

$$= x_i' \beta + \varepsilon_i,$$
 donde, $\beta' = (\beta_0, \beta_1, \dots, \beta_{p-1})$ en un vector de p parámetros,

$$\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n \text{ son v.a.i.i.d. tal que } \varepsilon_i \sim N(0, \tau) \text{ para } i=1, 2, \dots, n,$$

$$\text{con } \text{Var}(\varepsilon_i) = 1/\tau = \sigma^2.$$

Esto implica que

$$E(Y_i | \beta, \sigma^2, x_i) = x_i' \beta$$

$$\text{Var}(Y_i | \beta, \sigma^2, x_i) = 1/\tau = \sigma^2$$

□ Alternativamente, el modelo se puede escribir como:

$$Y_i | \beta, \tau, x_i \sim N(x_i' \beta, \tau), i=1, \dots, n$$

De manera conjunta, el modelo se puede expresar como:

$$Y | \beta, \tau, X \sim N(X\beta, \tau I)$$

donde, $Y' = (Y_1, \dots, Y_n)$, $\beta' = (\beta_0, \beta_1, \dots, \beta_{p-1})$,

$$X = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p-1} \\ 1 & x_{21} & \cdots & x_{2p-1} \\ 1 & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np-1} \end{pmatrix}.$$

□ OBJETIVOS:

- 1) Estimar el valor de los parámetros y determinar si el efecto particular de una variable explicativa es significativo o no.
- 2) Predicción de observaciones futuras Y_F , basados en un valor x_F ya sea conocido o hipotético, i.e.,

$$Y_F | \beta, \tau, x_F \sim N(x_F' \beta, \tau).$$

- El modelo de regresión lineal normal es un ejemplo de un modelo de regresión paramétrico y las variables explicativas sólo tienen efecto sobre la media de la distribución de la variable Y .

- Sin embargo, es posible que las variables explicativas no nadamás tengan un efecto sobre la media sino también sobre la varianza, i.e.,

$$E(Y_i | \beta, \sigma^2, x_i) = x_i' \beta$$

$$\text{Var}(Y_i | \beta, \sigma^2, x_i) = \sigma^2(x_i) \quad \text{e.g.} \quad \sigma^2(x_i) = e^{x_i' \gamma}$$

En este caso tendríamos un modelo de regresión a la media y a la varianza.

- NOTA: Cuidar el espacio parametral
- ANÁLISIS DEL MODELO: El análisis del modelo desde un punto de vista Bayesiano requiere de especificar una distribución inicial sobre los parámetros (β, τ) . recordemos que $\tau = 1/\sigma^2$ es la precisión de los errores.

Consideremos la función de verosimilitud,

$$f(y | \beta, \tau, X) \propto \tau^{n/2} \exp \left\{ -\frac{\tau}{2} (y - X\beta)' (y - X\beta) \right\}.$$

Escribiendo $y - X\beta = y - X\hat{\beta} + X(\hat{\beta} - \beta)$, la verosimilitud toma la forma,

$$f(y | \beta, \tau, X) \propto \tau^{n/2} \exp \left[-\frac{\tau}{2} \left\{ (n-p)s^2 + (\hat{\beta} - \beta)' X' X (\hat{\beta} - \beta) \right\} \right],$$

donde $\hat{\beta} = (X'X)^{-1} X'y$,

$$s^2 = \frac{1}{n-p} (y - X\hat{\beta})' (y - X\hat{\beta}).$$

A continuación consideraremos dos opciones de distribuciones iniciales y sus correspondientes distribuciones finales:

- *Análisis de referencia:*

Inicial: $\pi(\beta, \tau) \propto \tau^{-1}$

Final: $\pi(\beta, \tau | y, X) = N(\beta | \hat{\beta}, (X'X)\tau) \text{Ga}(\tau | (n-p)/2, (n-p)s^2/2),$

Marginalmente:

$$\pi(\beta | y, X) = \text{St}(\beta | \hat{\beta}, (X'X)(s^2)^{-1}, n-p)$$

$$\pi(\tau | y, X) = \text{Ga}(\tau | (n-p)/2, (n-p)s^2/2)$$

Predictiva final: Dado un vector de covariables x_F ,

$$\pi(y_F | y) = \text{St}\left(y_F \middle| x_F' \hat{\beta}, (1 + x_F'(X'X)^{-1}x_F)^{-1}(s^2)^{-1}, n-p\right).$$

○ *Análisis conjugado*:

Inicial: $f(\beta, \tau) = N(\beta | b_0, T_0\tau) \text{Ga}(\tau | a_0/2, c_0/2)$

Final: $f(\beta, \tau | y, X) = N(\beta | b_1, T_1\tau) \text{Ga}(\tau | a_1/2, c_1/2)$

donde, $b_1 = (X'X + T_0)^{-1}(X'X\hat{\beta} + T_0b_0)$

$$T_1 = X'X + T_0$$

$$a_1 = a_0 + n$$

$$c_1 = c_0 + (y - Xb_1)'(y - Xb_1) + (b_1 - b_0)'T_0(b_1 - b_0)$$

Nota: T_0 puede ser usada para romper multicolinealidad.

Marginalmente:

$$f(\beta | y, X) = \text{St}(\beta | b_1, T_1, a_1)$$

$$f(\tau | y, X) = \text{Ga}(\tau | a_1/2, c_1/2)$$

Predictiva final: Dado un vector de covariables x_F ,

$$f(y_F | y) = \text{St}\left(y_F \middle| x_F' b_1, \frac{a_1}{c_1} (1 + x_F' T_1 x_F)^{-1}, n-p\right).$$

- INFERENCIA: Recordemos que la inferencia se realiza utilizando la distribución final de los parámetros y la predictiva final.
 - *Estimación / Predicción puntual.* La estimación o predicción puntual puede realizarse utilizando alguna de las funciones de pérdida mencionadas anteriormente (cuadrática, absoluta o vecindad), obteniéndose la media, mediana o moda como estimadores o predictores puntuales.
 - *Pruebas de hipótesis.* La prueba de hipótesis más utilizada en regresión es sobre la significancia de las variables explicativas del modelo, i.e.,

$$H_0: \beta_j=0 \text{ vs. } H_1: \beta_j \neq 0$$

La forma común de tomar la decisión es obteniendo un intervalo de credibilidad de β_j al $(1-\alpha)$ de probabilidad, y si el intervalo contiene al cero se dice que la variable explicativa x_j no es significativa para el modelo, en caso contrario se dice que sí es significativa al nivel α .

- AJUSTE DEL MODELO. En estadística frecuentista, una forma de medir el ajuste del modelo es mediante el coeficiente de determinación. Este se construye de la siguiente manera:

Sea $\hat{y}_i = x_i' \hat{\beta}$ el predictor puntual máximo verosímil de y_i . Se definen

$$S_{YY} = \sum_{i=1}^n (y_i - \bar{y})^2 \text{ la variabilidad total de las observaciones}$$

$$SCR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \text{ la variabilidad explicada por la regresión}$$

$$SCE = \sum_{i=1}^n (\hat{y}_i - y_i)^2 \text{ la variabilidad no explicada por la regresión}$$

Se puede demostrar que

$$S_{YY} = SCR + SCE .$$

Entonces, una medida de la variabilidad explicada por el modelo es:

$$R^2 = \frac{SCR}{S_{YY}} \text{ (coeficiente de determinación).}$$

- *Nota 1.* La partición anterior de suma de cuadrados no es válida si en lugar del predictor máximo verosímil se usa algún otro predictor Bayesiano para y_i . Sin embargo es posible calcular $\{\text{Corr}(y_i, \hat{y}_i)\}^2$ como medida de ajuste, que en el caso de que \hat{y}_i sea el predictor máximo verosímil, coincidirá con R^2 .
- *Nota 2.* Para determinar el ajuste del modelo es mejor usar medidas de comparación de modelos como: LPML, medida-L y DIC.
- EJERCICIO 3. A continuación se presenta una base de datos de calificaciones de 20 empresas financieras hechas por las dos compañías calificadores más importantes S&P y Moody's. Realiza un análisis Bayesiano completo de los datos, ajustando un modelo de regresión lineal, tomando como variable respuesta las calificaciones de S&P y como variable explicativa las calificaciones de Moody's.
- EJERCICIO 4. Un investigador desea evaluar la relación entre el salario anual de trabajadores de una compañía de nivel medio y alto (Y , en miles de dólares) y el índice de calidad de trabajo (X_1), número de años de experiencia (X_2) y el índice de éxito en publicaciones (X_3). La muestra consiste de 24 trabajadores. Realiza un análisis Bayesiano completo de los datos y obtén las predicciones de salarios para 3 nuevos empleados con variables explicativas:

$$x_{1F}' = (5.4, 17, 6.0), x_{2F}' = (6.2, 12, 5.8) \text{ y } x_{1F}' = (6.4, 21, 6.1).$$

Modelos lineales generalizados

- Recordemos que el modelo de regresión lineal es una forma de describir la relación entre una variable respuesta “y” y un conjunto de variables explicativas $x' = (x_1, \dots, x_p)$. Una forma más general de describir la distribución condicional de Y dado X, $f(y|\beta, x)$, es mediante la clase de modelos lineales generalizados.

- La idea general de los modelos lineales generalizados consiste en modelar el valor esperado de Y, digamos $\mu(x) = E(Y|x)$, a través de una función paramétrica simple de las variables explicativas, digamos $\varphi(\beta, x)$, i.e.,

$$\mu(x) = \varphi(\beta, x).$$

- Al considerar distintas distribuciones para la variable respuesta Y y distintas formas para la función $\varphi(\cdot)$, este modelo produce una clase muy amplia de modelos de regresión generalizados.
- Los modelos lineales generalizados suponen que la función de densidad de la variable respuesta Y (discreta o continua) es un miembro de la familia exponencial, i.e.,

$$f(y|\theta, \phi) = b(y, \phi) \exp[\phi\{y\theta - a(\theta)\}]$$

donde $a(\cdot)$ y $b(\cdot)$ son funciones monótonas. El parámetro ϕ es un parámetro de dispersión y cuando es conocido describe una familia exponencial natural. La media y la varianza de Y están dadas por:

$$\mu = E(Y|\theta) = a'(\theta) \quad \text{y} \quad \text{Var}(Y|\theta) = \frac{a''(\theta)}{\phi}.$$

- **MODELO:** Los modelos lineales generalizados se describen a través de una componente aleatoria, una componente sistemática y una función liga:

- **Componente aleatoria:** Sean Y_1, Y_2, \dots, Y_n v.a.i. de la función de densidad

$$f(y_i | \theta_i, \phi_i) = b(y_i, \phi_i) \exp[\phi_i \{y_i \theta_i - a(\theta_i)\}]$$

- **Componente sistemática:** Para cada respuesta Y_i se tiene un vector de covariables o variables explicativas $x_i' = (1, x_{i1}, \dots, x_{ip-1})$ las cuales producen el predictor lineal

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{ip-1} = x_i' \beta$$

- **Función liga:** Las componentes aleatoria y sistemática se relacionan a través de una función liga $g(\cdot)$, tal que

$$\eta_i = g(\mu_i).$$

Un caso particular importante se obtiene cuando $g^{-1}(\cdot) = a'(\cdot)$. En este caso, $\eta_i = \theta_i$ y $g(\cdot)$ es llamada liga canónica.

- **CASOS PARTICULARES:** Algunos de los modelos lineales generalizados más usados en la práctica son el Normal, el Poisson y el Bernoulli.

Sean Y_1, Y_2, \dots, Y_n v.a.i. de la función de densidad

- **Normal:** $Y_i | \mu_i \sim N(\mu_i, \tau_i), \mu_i \in \mathcal{R}$

$$f(y_i | \mu_i, \tau_i) = (2\pi/\tau_i)^{-1/2} \exp\left\{-\frac{\tau_i}{2}(y_i - \mu_i)^2\right\} I_{(-\infty, \infty)}(y_i), \text{ donde}$$

$$\begin{cases} \phi_i = \tau_i \\ b(y_i, \phi_i) = (2\pi/\phi_i)^{-1/2} \exp\left\{-\frac{\phi_i}{2} y_i^2\right\} \\ \theta_i = \mu_i \\ a(\theta_i) = \frac{\theta_i^2}{2} \Rightarrow a'(\theta_i) = \theta_i \end{cases}$$

Liga canónica: $g(\mu_i) = \mu_i$

$\therefore \mu_i = \eta_i = x_i' \beta$ (modelo lineal)

○ Poisson: $Y_i | \mu_i \sim \text{Po}(\mu_i)$, $\mu_i \in \mathcal{R}^+$

$$f(y_i | \mu_i) = e^{-\mu_i} \frac{\mu_i^{y_i}}{y_i!} I_{\{0,1,\dots\}}(y_i), \text{ donde}$$

$$\begin{cases} \phi_i = 1 \\ b(y_i, \phi_i) = b(y_i) = \frac{1}{y_i!} I_{\{0,1,\dots\}}(y_i) \\ \theta_i = \log \mu_i \\ a(\theta_i) = e^{\theta_i} \Rightarrow a'(\theta_i) = e^{\theta_i} \end{cases}$$

Liga canónica: $g(\mu_i) = \log \mu_i$

$\therefore \log \mu_i = \eta_i = x_i' \beta$ (modelo log-lineal)

○ Bernoulli: $Y_i | \mu_i \sim \text{Ber}(\mu_i)$, $\mu_i \in (0,1)$

$$f(y_i | \mu_i) = \mu_i^{y_i} (1 - \mu_i)^{1-y_i} I_{\{0,1\}}(y_i), \text{ donde}$$

$$\begin{cases} \phi_i = 1 \\ b(y_i, \phi_i) = b(y_i) = I_{\{0,1\}}(y_i) \\ \theta_i = \log\left(\frac{\mu_i}{1 - \mu_i}\right) \\ a(\theta_i) = \log(1 + e^{\theta_i}) \Rightarrow a'(\theta_i) = e^{\theta_i} / (1 + e^{\theta_i}) \end{cases}$$

Liga canónica: $g(\mu_i) = \log\left(\frac{\mu_i}{1 - \mu_i}\right)$

$$\therefore \log\left(\frac{\mu_i}{1 - \mu_i}\right) = \eta_i = x_i' \beta \text{ (modelo logístico)}$$

Otras ligas: $g(\mu_i) = \Phi^{-1}(\mu_i)$, donde $\Phi(\cdot)$ es la función de distribución normal estándar $\therefore \mu_i = \Phi(\eta_i) = \Phi(x_i' \beta)$ (modelo probit)

- **ANÁLISIS DEL MODELO:** Consideremos la forma general del modelo lineal generalizado, en donde las observaciones Y_1, Y_2, \dots, Y_n son un conjunto de v.a.i. de la función de densidad

$$f(y_i | \theta_i, \phi_i) = b(y_i, \phi_i) \exp[\phi_i \{y_i \theta_i - a(\theta_i)\}], \quad i=1, \dots, n.$$

Por simplicidad supongamos que ϕ_i es conocido y que las componentes aleatoria y sistemática se relacionan a través de la liga canónica, i.e., $\theta_i = \eta_i = x_i' \beta$. En este caso, la función de verosimilitud es de la forma,

$$f(y|\beta) \propto \exp\left[\sum_{i=1}^n \phi_i \{y_i (x_i' \beta) - a(x_i' \beta)\}\right].$$

Inicial: $f(\beta) = N(\beta | b_0, T_0)$

Final: $f(\beta | y, X) \propto \exp\left[\sum_{i=1}^n \phi_i \{y_i (x_i' \beta) - a(x_i' \beta)\} - \frac{1}{2}(\beta - b_0)' T_0 (\beta - b_0)\right]$

Predictiva final: Dado un vector de covariables x_F y un valor ϕ_F ,

$$f(y_F|y) = \int f(y_F|x_F'\beta, \phi_F) f(\beta|y, X) d\beta = E_{\beta|y, X} \{f(y_F|x_F'\beta, \phi_F)\}.$$

- AJUSTE DEL MODELO. Existen varias formas de medir la bondad del ajuste de un modelo. En modelos lineales generalizados la medida más común es la *devianza*, la cual se define como dos veces el logaritmo del cociente de verosimilitudes, es decir,

$$\text{Dev} = 2 \log \frac{L(\tilde{\theta} | y)}{L(\hat{\theta} | y)},$$

donde $\hat{\theta}$ y $\tilde{\theta}$ son los valores maximizados de θ en dos modelos diferentes.

En el caso de modelos lineales generalizados la *devianza* toma la forma:

$$\text{Dev} = 2 \sum_{i=1}^n \phi_i \{y_i (\tilde{\theta}_i - \hat{\theta}_i) - a(\tilde{\theta}_i) + a(\hat{\theta}_i)\}.$$

Para los tres casos particulares de modelos lineales generalizados vistos anteriormente, la *devianza* es de la forma:

MODELO	DEVIANZA
Normal	$\sum_{i=1}^n (y_i - \hat{\mu}_i)^2$
Poisson	$2 \sum_{i=1}^n \left\{ y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) - (y_i - \hat{\mu}_i) \right\}$
Bernoulli	$2 \sum_{i=1}^n \left\{ y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) + (1 - y_i) \log \left(\frac{1 - y_i}{1 - \hat{\mu}_i} \right) \right\}$

donde $\hat{\mu}_i$ es el predictor puntual de y_i .

- NOTA. La Devianza es la medida de ajuste frecuentista usada para los modelos lineales generalizados, son embargo en el caso Bayesiano es posible usar la medida equivalente DIC definida anteriormente.

- EJERCICIO 7. Tasas de mortalidad (Congdon, 2001). Una compañía de seguros quiere lanzar un nuevo seguro médico para mineros. Para ello desea estimar la probabilidad de muerte (π_i), con base en el tiempo de exposición al mineral (x_i en horas). Se cuenta con información de las muertes registradas entre 1950 y 1959, junto con el tiempo de exposición al mineral y el número de mineros expuestos. Realiza un análisis Bayesiano de los datos y obtén la distribución predictiva del número de muertes suponiendo que hay 100 mineros con un tiempo de exposición de 200 horas. El modelo es el siguiente: Para $i=1,\dots,N$

$$Y_i | \pi_i \sim \text{Bin}(n_i, \pi_i)$$

$$\text{logit}(\pi_i) = \beta_0 + \beta_1 x_i$$

con $\beta_0 \sim N(0, 0.001)$ y $\beta_1 \sim N(0, 0.001)$.

- EJERCICIO 8. En el mismo contexto del problema anterior, supongamos ahora que la compañía de seguros está interesada en modelar el número total de desastres (Y_t) que ocurren en la mina. Se cuenta con $N=112$ observaciones durante los años 1851 a 1962. Se proponen tres modelos:

a) Modelo con tasa variable en función del tiempo:

$$Y_t | \mu_t \sim \text{Po}(\mu_t)$$

$$\log(\mu_t) = \beta_0 + \beta_1 t$$

con $\beta_0 \sim N(0, 0.001)$ y $\beta_1 \sim N(0, 0.001)$.

- b) Modelo con tasa constante en dos períodos: Se cree que la tasa promedio de desastres es constante, pero que en el siglo XX la tasa ha disminuido. Esto se traduce en el siguiente modelo:

$$Y_t | \mu_t \sim \text{Po}(\mu_t)$$

$$\log(\mu_t) = \beta_0 + \beta_1 I(t \geq \tau)$$

con $\beta_0 \sim N(0, 0.001)$, $\beta_1 \sim N(0, 0.001)$ y $\tau \sim U\{1, \dots, N\}$.

- c) Modelo Poisson dinámico:

Observación: $Y_t | \mu_t \sim \text{Po}(\mu_t)$, $\log \mu_t = \eta_t$

Evolución: $\eta_t = \eta_{t-1} + \omega_t$, $\omega_t \sim N(0, W^{-1}) \Rightarrow \eta_t | \eta_{t-1} \sim N(\eta_{t-1}, W^{-1})$

con $\eta_1 \sim N(0, 0.0001)$ y $W^{-1} \sim \text{Ga}(0.01, 0.01)$.